PROCES UCZENIA MASZYNOWEGO

Od pomysłu do modelu w praktyce

CO TO ZNACZY „*PROCES ML*"?

To nie tylko algorytm – to **cykl uczenia**, który obejmuje wiele etapów:

Dane wejściowe

→

Trenowanie modelu

→

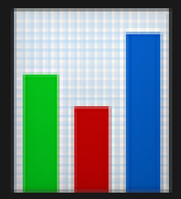

Ocena skuteczności

→

Wdrożenie modelu

👨‍🍳 JAK AI SIĘ UCZY? (WERSJA KULINARNA)

- Dane = składniki
- Model = kucharz z przepisem
- Funkcja kosztu = czy danie smakuje?
- Optymalizacja = próbuję inaczej, aż będzie lepiej

📌 AI nie uczy się faktów. Uczy się wzorców z danych, które widziało.

1. OKREŚLENIE CELU – PRZYKŁAD BIZNESOWY

Chcemy automatycznie tagować zgłoszenia IT

2. DANE – SKĄD JE WZIĄĆ I CO Z NIMI ZROBIĆ?

- Dane bywają brudne, niepełne, niejednolite
- Czyszczenie, uzupełnianie, standaryzacja
- Kodowanie tekstu / liczb / kategorii

🧹 CZY DANE SĄ KIEDYKOLWIEK CZYSTE?

🧠 Pytanie do Ciebie:

- Czy pracowałeś(-aś) kiedyś z "brudnymi" danymi?
- Skąd pochodziły? Co było największym wyzwaniem?

📩 Podziel się jednym wspomnieniem

"MÓWIĄCE DANE" – JAK UPORZĄDKOWAĆ DANE Z ŻYCIA CODZIENNEGO?

👉 **Sytuacja:** Pracujesz w dziale IT dużej firmy. Każdego dnia spływają setki zgłoszeń z różnych źródeł:

- 📧 E-maile (długie, pisane swobodnie)
- 💬 Czat z klientem (krótkie, chaotyczne)
- 📝 Formularze (częściowo uporządkowane)

Twoim zadaniem jest uporządkowanie tych danych, by mogły posłużyć do trenowania modelu AI, który automatycznie przypisuje kategorię zgłoszenia (np. 'problem techniczny', 'reklamacja', 'pytanie').

🧠 **Jak się za to zabierzesz?**

📝 KROK PO KROKU:

- **1. Zidentyfikuj źródła danych:** czy wszystkie zgłoszenia mają podobną strukturę?
- **2. Rozpoznaj problemy:** czy ludzie piszą bezbłędnie?
- **3. Wyczyść dane:** co zrobić z duplikatami, skrótami, synonimami?
- **4. Przygotuj dane do modelu:** jak sprawić, by dane były „zrozumiałe" dla ML?

➡️ **10 minut na zastanowienie się + 5 minut dyskusji live / na czacie**

~14:35 wracamy z odpowiedziami

✅ PRZYKŁADOWE ROZWIĄZANIE – JAK UPORZĄDKOWAĆ DANE?

Oto jak mógłby wyglądać przykładowy plan przygotowania danych:

📦 ETAPY:

- **1. Źródła danych:** E-mail (tekst/HTML – czasem rozbity na nagłówki i treść), czat (krótkie wiadomości, często niepełne zdania), formularze (zwykle lepsza struktura, ale możliwe błędy w polach).
- **2. Problemy:** Różne sposoby opisywania tych samych rzeczy ("drukarka nie działa" vs "awaria drukarki"), literówki ("rekamacjia", "drukakra"), mieszanie języków (np. PL + EN).
- **3. Czyszczenie danych:** Mapowanie synonimów (tworzenie słownika zamienników), standaryzacja wpisów (np. "drukarka" → "drukarka HP"), usuwanie duplikatów, poprawa oczywistych literówek lub automatyczne sugestie.
- **4. Przygotowanie do ML:** Tworzenie kategorii zgłoszeń ("problem techniczny", "pytanie", "reklamacja"), zamiana tekstu na liczby (tokenizacja, TF-IDF, embeddings) — tak, by model mógł się uczyć na danych liczbowych, nie bezpośrednio na tekście.

🎯 **Cel:** Dane muszą być spójne, zrozumiałe dla modelu i możliwe do powtórzenia w przyszłości (reproducibility!).

3. TRENOWANIE MODELU

- Uczymy na danych z etykietami (np. 'bug' vs 'feature')
- Wybór modelu (np. regresja, drzewa decyzyjne)
- Dzielimy dane na treningowe/testowe

😼 CONFUSION MATRIX – JAK JĄ ZROZUMIEĆ?

Załóżmy, że robimy model AI, który wykrywa 🐱 koty na kamerach monitoringu.

	🔍 Model mówi	
🎯 **Rzeczywistość**	**To kot**	**To nie kot**
To naprawdę był kot	✅ **True Positive** model wykrył kota	❌ **False Negative** model przegapił kota
To nie był kot	❌ **False Positive** model pomylił psa z kotem	✅ **True Negative** model poprawnie zignorował

🔁 Te cztery liczby to cała podstawa analizy jakości modelu

4. OCENA I TUNING

- Metryki: accuracy, precision, recall, F1
- Analiza błędów (confusion matrix)
- Tuning hiperparametrów

Confusion matrix (przykład)

	Pred: Bug	**Pred: Feature**
Actual: Bug	96	4
Actual: Feature	18	22

🟩 = trafienia, liczby poza przekątną = błędy modelu

5. WDROŻENIE I MONITORING

- Model jako API / mikrousługa
- Wersjonowanie danych i modeli
- Monitorowanie jakości predykcji

ĆWICZENIE: ZDEFINIUJ WŁASNY PROJEKT ML

Napisz krótko w czacie:

- Problem: co AI miałoby rozwiązać?
- Dane: skąd je masz?
- Cel: co ma przewidywać?

✅ PRZYKŁAD PROJEKTU ML – NIEOCZYWISTE ZASTOSOWANIE

🎯 **Cel:** Pomóc zespołowi HR w przewidywaniu rotacji pracowników

- **Problem:** HR chce zidentyfikować pracowników, którzy mogą odejść w ciągu najbliższych 6 miesięcy.
- **Dane:** Historia zatrudnienia, liczba dni urlopu, liczba nadgodzin, wyniki ocen rocznych, udział w szkoleniach.
- **Model przewiduje:** Prawdopodobieństwo odejścia z firmy (churn prediction).

📌 To tylko jeden przykład – inne projekty mogą dotyczyć np. logistyki, obsługi klienta, analizy błędów testów, sprzedaży, helpdesku…

🍽️ PRZERWA OBIADOWA – 30 MINUT

Wracamy 15:00

DEMO – KLASYFIKATOR SPAM VS NIE-SPAM

Mini-projekt: wykrywanie spamu na podstawie treści wiadomości

- Dane: krótkie wiadomości e-mail (np. „Win a prize", „Meeting at 10am")
- Model: Logistic Regression / Naive Bayes
- Wynik: klasyfikacja SPAM / NIE-SPAM + prawdopodobieństwo

ĆWICZENIE: SPRAWDŹ SWÓJ TEKST!

📩 Wpisz własną wiadomość e-mail i zobacz, czy zostanie uznana za spam

- Zmień tekst i zobacz wynik + prawdopodobieństwo
- Przetestuj różne przypadki (np. „free offer", „deadline change")
- Spróbuj zgadnąć, które słowa mają największy wpływ!

🛠️ ROZSZERZENIE ĆWICZENIA – KLASYFIKATOR SPAM/NIE-SPAM

- **Dodaj własne dane**
  - Dodaj po 3 wiadomości SPAM i 3 NIE-SPAM.
  - Wymyśl je samodzielnie lub podejrzyj w mailach.
  - *Podpowiedź:* użyj `X.extend([...])` i `y.extend([...])`
- **Przetestuj własne wiadomości**
  - Wpisz 5 własnych przykładów tekstu.
  - Sprawdź, jak model je klasyfikuje: SPAM czy NIE-SPAM.
  - *Podpowiedź:* użyj `model.predict(...)`
- **Eksperymentuj z parametrami**
  - Zmień ustawienia `CountVectorizer`.
  - Przykłady:
    - `stop_words='english'`
    - `ngram_range=(1,2)`
  - *Podpowiedź:* `CountVectorizer(stop_words='english', ngram_range=(1,2))`
- **Krótka refleksja**
  - Co bardziej wpływa na skuteczność: lepszy model czy lepsze dane?

☕ PRZERWA KAWOWA – 15 MINUT

Czas na kawę!

Wracamy o ...

🧬 KREATYWNE MYŚLENIE: AI W NIETYPOWYM MIEJSCU

Gdzie AI mogłoby działać, a dziś jeszcze tam go nie ma?

- 🧐 Analiza humoru w mailach?
- 🎨 Automatyczne tworzenie playlist na podstawie nastroju?
- 🛒 Optymalizacja zakupów spożywczych?

👉 Wymyśl własny pomysł i napisz na czacie!

🚫 BŁĘDY POCZĄTKUJĄCYCH W AI / ML

- 🔢 Użycie za małej liczby danych – model „uczy się na pamięć"
- 🔁 Trening i test na tych samych danych – zafałszowane wyniki
- 🔍 Skupienie się na modelu, a nie na jakości danych
- 🧪 Brak walidacji – nie wiemy, jak model działa poza labem
- 🏗️ Zbyt skomplikowany model do prostego problemu
- 🎯 Optymalizacja „na metryki", a nie na realny problem

🧠 W ML najpierw zrozum problem. Potem modeluj.

PRZEJDŹ DO CZĘŚCI 3

➡️ Część 3: Typy uczenia maszynowego