🚀 WITAJ W DNIU 2!

- 🤖 Zanurzymy się w świat LLM (Large Language Models)
- 🧠 Od promptów do Context Engineering – jak naprawdę sterować AI w 2026
- 🔧 Zbudujemy własnego agenta AI w Pythonie
- 🔗 Orkiestracja agentów z LangGraph

🌟 Dziś 75% czasu to praktyka – pisanie kodu, eksperymenty, budowanie

📅 AGENDA – DZIEŃ 2

- **09:00–10:30** – Jak działają LLM-y
  - Tokenizacja – wyścig + quiz
  - Attention i Transformer
  - Ćwiczenie: LLM + RAG w praktyce
- **10:30–10:45** – ☕ Przerwa kawowa
- **10:45–12:15** – Context Engineering
  - Od promptów do kontekstu – podejście 2026
  - Tool calling i structured outputs
  - Ćwiczenie: Chatbot Arena + Ollama Modelfile
- **12:15–12:45** – Architektura agentów AI
  - Krótka teoria + ćwiczenie: whiteboard design
- **12:45–13:45** – 🍽️ Przerwa obiadowa
- **13:45–14:45** – Warsztat: Python Agent
  - Budujemy agenta IT krok po kroku
  - Tools, memory, structured output
- **14:45–15:00** – ☕ Przerwa kawowa
- **15:00–16:15** – Orkiestracja z LangGraph
  - Grafy, węzły, krawędzie warunkowe
  - Ćwiczenie: inteligentny router zgłoszeń
- **16:15–16:45** – Ryzyka AI + podsumowanie
  - Prompt injection attack, bezpieczeństwo AI
  - Refleksja i dalsze kroki

🤖 CO TO SĄ LLM-Y?

- LLM = Large Language Model
- Trenowany na miliardach tokenów
- Przewiduje kolejne słowa/tokeny – nie rozumie, ale zgaduje (i to świetnie)

🔧 JAK DZIAŁA LLM?

- W środku: architektura Transformer
- Tekst zamieniany na tokeny
- Model uczy się zależności i „zgaduje" następny token

🔤 JAK TEKST ZAMIENIA SIĘ W TOKENY?

Wejście: `I love machine learning!`

Tokeny: I | love | machine | learning | !

⚠️ Czasem token to **całe słowo**, czasem tylko **kawałek słowa** (np. „learn" i „ing")

🔢 OD TEKSTU DO TOKENÓW

- „AI is powerful" → `[7412, 318, 5939]` – tokeny
- Tokeny = liczby całkowite reprezentujące fragmenty tekstu
- Te liczby trafiają do warstwy **embedding**, która przypisuje im znaczenie w przestrzeni

🎯 WYŚCIG TOKENIZACJI!

👉 Teraz zobaczymy, jak modele AI naprawdę "widzą" tekst.

🔍 Ile tokenów ma słowo? Emoji? Liczba?

💻 Otwieramy notebook Colab!

🧠 TOKENIZACJA NIE ZAWSZE JEST OCZYWISTA

Wejście: `unbelievable` 😱🔥

Tokeny: un | believ | able | 😱 | 🔥

🧩 Nawet jedno słowo może rozbić się na 3 tokeny, a emoji mogą być tokenami osobno!

QUIZ: TOKENIZACJA

Reaguj na Zoomie:

🤫 = 1 token | 👍 = 2-3 tokeny | 🎉 = 4+ tokenów

QUIZ 1/6

"Hello world!"

🤫 1 | 👍 2-3 | 🎉 4+

QUIZ 1/6 - ODPOWIEDŹ

"Hello world!"

➡️ **3 tokeny** (👍)

QUIZ 2/6

"Dziękuję!"

😲 1 | 👍 2-3 | 🎉 4+

QUIZ 2/6 - ODPOWIEDŹ

"Dziękuję!"

➡️ **5 tokenów** (🎉)

QUIZ 3/6

"ChatGPT is amazing 🤯"

😲 1 | 👍 2-3 | 🎉 4+

QUIZ 3/6 - ODPOWIEDŹ

"ChatGPT is amazing 🤯"

➡️ **6 tokenów** (🎉)

QUIZ 4/6

"unbelievable"

😲 1 | 👍 2-3 | 🎉 4+

QUIZ 4/6 - ODPOWIEDŹ

"unbelievable"

➡️ **3 tokeny** (👍)

QUIZ 5/6

"123-456-7890"

🤫 1 | 👍 2-3 | 🎉 4+

QUIZ 5/6 - ODPOWIEDŹ

"123-456-7890"

➡️ **6 tokenów** (🎉)

QUIZ 6/6

"　　は" (japońskie "Dzień dobry")

😲 1 | 👍 2-3 | 🎉 4+

QUIZ 6/6 - ODPOWIEDŹ

"　　は"

➡️ 1 token (😗)

👂 ATTENTION – JAK TO DZIAŁA?

Wyobraź sobie, że jesteś na zatłoczonej konferencji.

Wokół ciebie dziesiątki rozmów – ale Twój mózg automatycznie skupia się na jednym głosie.

Właśnie to robi **attention**: waży, które informacje są ważne, a które może zignorować.

I | love | **ML**

Model „słyszy" wszystko, ale skupia się najbardziej na słowie **ML** jako najważniejszym w kontekście.

🧠 JAK DZIAŁA LLM?

Wejście: `I love ML`

Tokenizacja: I | love | ML

Attention: model analizuje zależności między tokenami

(np. „love" → silny związek z „ML")

Predykcja: because (albo „so much", „since", itd.)

🔗 JAK TO WSZYSTKO SIĘ ŁĄCZY?

Tokeny ➡️ Wektory ➡️ Attention ➡️ Predykcja ➡️ Nowe tokeny

- Z małych kroków budujemy potężny model tekstowy 📚
- Każdy element (embedding, attention, predykcja) to trybik w wielkiej maszynie

🛠️ Zobaczmy, jak wygląda cała konstrukcja – Transformer!

SCHEMAT TRANSFORMER

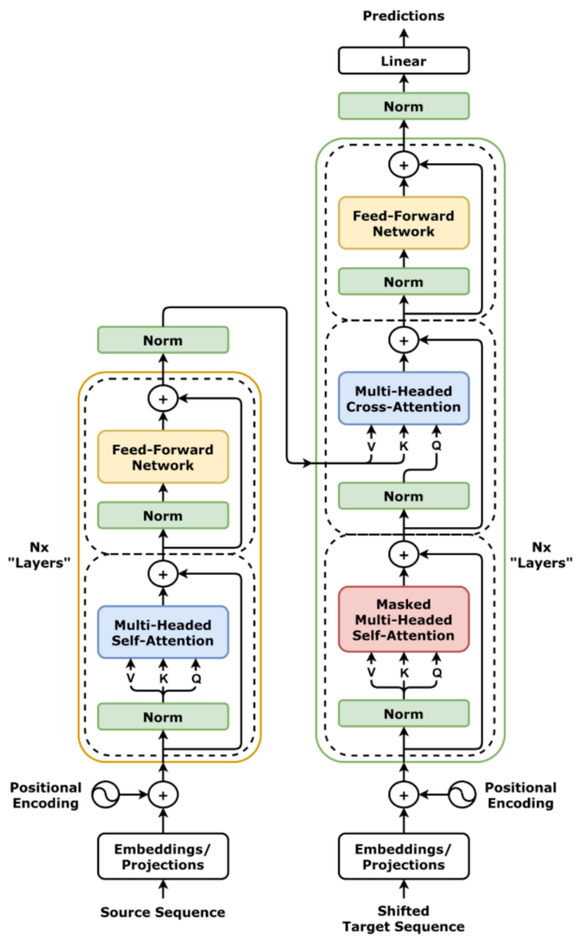

🔬 TRANSFORMER EXPLAINER – DEMO

Zobaczymy działanie Transformera na żywo w przeglądarce!

👉 poloclub.github.io/transformer-explainer

- Wpiszcie zdanie i zobaczcie, jak przepływa przez model
- Kliknijcie na attention heads – zobaczcie, na co model zwraca uwagę
- Każdy krok wizualizowany: embedding → attention → output

🧪 ĆWICZENIE: LLM VS RAG W KLASYFIKACJI

- 🤖 Użyjemy prawdziwego LLM do klasyfikacji zgłoszeń IT
- 📋 Te same 10 zgłoszeń, które klasyfikowaliśmy ręcznie i z ML wczoraj
- 🔍 Zobaczymy, jak RAG (dodanie kontekstu) zmienia wyniki
- 📊 Porównamy: człowiek vs ML vs LLM vs RAG

💻 Otwieramy **combined_exercise.ipynb** – Część 4 i 5!

☕ PRZERWA KAWOWA – 15 MINUT

Czas na kawę!

Wracamy o 10:45

PRZEJDŹ DO CZĘŚCI 2

➡️ Część 2: Context Engineering i Agenci AI